python:WEBアプリを作ろう（djangoでスクレイピング）

31

tamurasann
2020/05/02 21:46

今回は、pythonのWebフレームワークのdjangoを使って、YahooNewsのURLを入力すれば、そのURLに記載されているタイトルとURLを抽出し、違うページに簡単にタイトルとURLを表示するような無意味なWebアプリを作ってみましょう。

News

タイトル	URL
憲法に緊急事態条項 首相訴えへ	https://news.yahoo.co.jp/pickup/6358781
死者500人超 大都市圏に多数	https://news.yahoo.co.jp/pickup/6358779
都・大阪知事 9月入学求める	https://news.yahoo.co.jp/pickup/6358778
延長「特定警戒」増やす方針	https://news.yahoo.co.jp/pickup/6358751
自分さえよければ 壊す社会	https://news.yahoo.co.jp/pickup/6358749
施設出身 コロナで「孤独感」	https://news.yahoo.co.jp/pickup/6358774
「3ない」健康麻雀 卓囲めず	https://news.yahoo.co.jp/pickup/6358773
密避けられない 登山も自粛を	https://news.yahoo.co.jp/pickup/6358770

目次

すべて表示

projectの作成

```
django-admin startproject newsproject .
```

アプリの作成

```
python3 manage.py startapp newsapp
```

templatesフォルダの作成

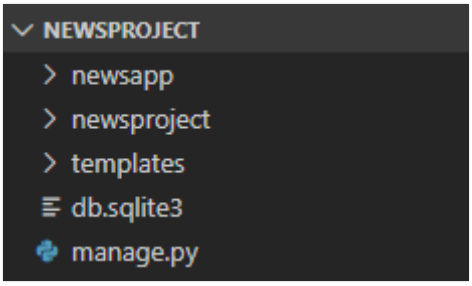

※manage.pyが存在するフォルダに作成。後ほど、このフォルダにURLオブジェクトを作るためのページと情報を表示するためのページ。bootstapを使うためのhtmlを作成し、入れ込みます。

newsprojectのsetting.pyの編集

```
INSTALLED_APPS = [
    'django.contrib.admin',
    'django.contrib.auth',
    'django.contrib.contenttypes',
    'django.contrib.sessions',
    'django.contrib.messages',
```

```
    'django.contrib.staticfiles',
    'newsapp', #追記
]
```

作ったアプリ名を追記します。

```
TEMPLATES = [
    {
        'BACKEND': 'django.template.backends.django.DjangoTemplates',
        'DIRS': [BASE_DIR, 'templates'], #追記
        'APP_DIRS': True,
        'OPTIONS': {
            'context_processors': [
                'django.template.context_processors.debug',
                'django.template.context_processors.request',
                'django.contrib.auth.context_processors.auth',
                'django.contrib.messages.context_processors.messages',
            ],
        },
    },
]
```

BASE_DIRは、manage.pyがあるフォルダを示し、その中のtemplatesフォルダをTEMPLATESとみなすような設定です。

newsprojectのurls.pyの編集

```
from django.contrib import admin
from django.urls import path, include#追記
urlpatterns = [
    path('admin/', admin.site.urls),
    path('', include('newsapp.urls')), #追記
]
```

localhost:8000にアクセスするとnewsapp.urlsを見に行くような設定です。

アプリフォルダにurls.pyを作成し、編集

```
from django.urls import path
from .views import Create, listfunc

urlpatterns = [
   path('', Create.as_view(), name='home'),
   path('list/', listfunc, name='list'),
]
```

localhost:8000にアクセスされた場合、Createクラスが実行され、localhost:8000/list/にアクセスすると listfuncが実行されるような設定です。

Createクラスとlistfuncは後で作成します。

アプリフォルダのviews.pyを編集

```
from django.shortcuts import render
from .models import News
from django.views.generic import CreateView
from django.urls import reverse_lazy
import urllib.request
import requests
from bs4 import BeautifulSoup


class Create(CreateView):
```

```
    template_name = 'home.html'
    model = News
    fields = ('url',)
    success_url = reverse_lazy('list')


def listfunc(request):
    for post in News.objects.all():
        url = post.url
    list = []
    response = requests.get(url)
    bs = BeautifulSoup(response.text, "html.parser")
    ul_tag = bs.find_all(class_="topicsList_main")
    for tag in ul_tag[0]:
        title = tag.a.getText()
        url2 = tag.a.get("href")
        list.append([title, url2])
    context = {'list': list,}
    return render(request, 'list.html', context)
```

Createクラスでフォームから受け取ったurlオブジェクトを作成し、lisufuncで

そのurlオブジェクトを使ってスクレイピングしています。もっと簡単な方法があると思いますが、今回は、上記のような感じで作成しました。

アプリフォルダのmodels.pyを編集

```
from django.db import models

class News(models.Model):
    url = models.CharField(max_length=100)
```

マイグレーションを行う

```
python3 manage.py makemigrations
```

```
python3 manage.py migrate
```

base.htmlを作成

```
<!doctype html>
<html lang="en">
 <head>
   <!-- Required meta tags -->
   <meta charset="utf-8">
   <meta name="viewport" content="width=device-width, initial-scale=1, shrink-to-fit=no">
   <!-- Bootstrap CSS -->
   <link rel="stylesheet" href="https://stackpath.bootstrapcdn.com/bootstrap/4.4.1/css/bootstra
   <title>Pachi Data</title>
 </head>
 <body>
   {% block header %}
   {% endblock header %}
   {% block content %}
   {% endblock content %}
   <!-- Optional JavaScript -->
   <!-- jQuery first, then Popper.js, then Bootstrap JS -->
   <script src="https://code.jquery.com/jquery-3.4.1.slim.min.js" integrity="sha384-J6qa4849blE
   <script src="https://cdn.jsdelivr.net/npm/popper.js@1.16.0/dist/umd/popper.min.js" integrity
   <script src="https://stackpath.bootstrapcdn.com/bootstrap/4.4.1/js/bootstrap.min.js" integri
 </body>
</html>
```

※boostrapのStarterTemplateを貼り付け、bodyの中にblock headerとblock contentを追記しています。

home.htmlを作成

```
{% extends 'base.html' %}

{% block header %}
<div class="jumbotron">
   <div class="container">
     <h1 class="display-4">News</h1>
     <p class="lead">Enter the URL</p>
   </div>
 </div>
{% endblock header %}

{% block content %}
<div class="container">
<form action='' method='POST'>{% csrf_token %}
<p>URL :  <input type="text" name='url'></p>
<input type="submit" value="取得する">
</form>
</div>
{% endblock content %}
```

URLオブジェクトを作成するためのトップページです。

list.htmlを作成

```
{% extends 'base.html' %}

{% block header %}
```

```
<div class="jumbotron">
   <div class="container">
     <h1 class="display-4">News</h1>
   </div>
 </div>
{% endblock header %}

{% block content %}
<div class="container">
<ul class="list-group list-group-flush">
 <table border="2">
   <tr>
     <th>タイトル</th>
     <th>URL</th>
   </tr>
   {% for post, post2 in list %}
   <tr>
     <td>{{ post }}</td>
     <td><a href="{{ post2 }}">{{ post2 }}</a></td>
   </tr>
   {% endfor %}
 </table>
</ul>
</div>
{% endblock content %}
```

データを表示させるためのページです。

以上で完成となります。以下のコードでサーバーを起動して、確認してみてください。

```
python3 manage.py runserver
```

最終的な構成は以下のような感じです。

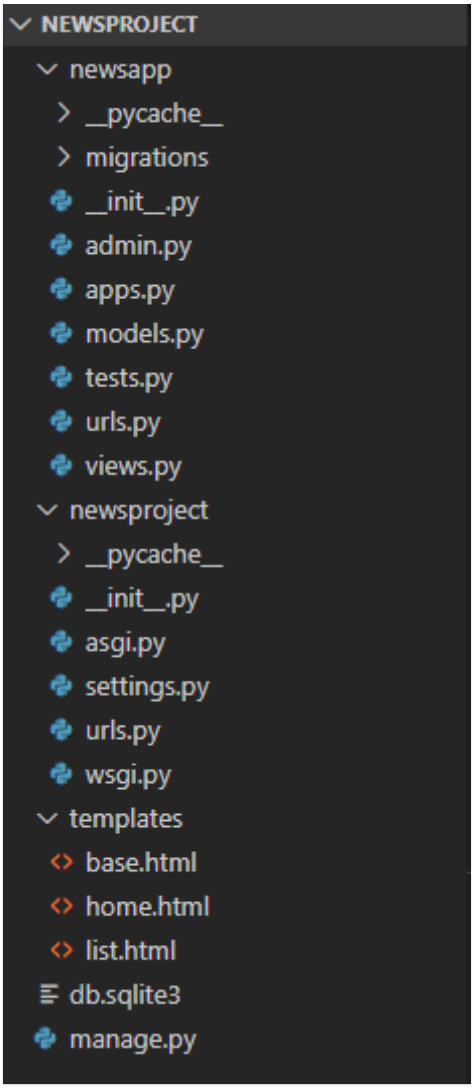
NEWSPROJECT
newsapp
__pycache__
migrations
__init__.py
admin.py
apps.py
models.py
tests.py
urls.py
views.py
newsproject
__pycache__
__init__.py
asgi.py
settings.py
urls.py
wsgi.py
templates
base.html
home.html
list.html
db.sqlite3
manage.py